

Implementación de Sistemas de Visión Computacional y Teledetección para la Monitorización y Detección de Minería Ilegal en la Amazonía y Regiones Altoandinas

El ecosistema amazónico y las zonas vulnerables de los Andes peruanos enfrentan una crisis sin precedentes derivada de la expansión descontrolada de la minería ilegal. Esta actividad no solo actúa como un motor primario de la deforestación, sino que desencadena una degradación ambiental sistémica que compromete la biodiversidad, altera los ciclos hidrológicos y afecta la salud de las poblaciones locales debido a la contaminación por metales pesados como el mercurio. En este escenario, la capacidad de respuesta de las autoridades se ve limitada por la inaccesibilidad geográfica de los frentes mineros y la rapidez con la que estos se desplazan. Por lo tanto, el desarrollo de un modelo automatizado basado en visión computacional e imágenes satelitales representa la frontera tecnológica necesaria para establecer un sistema de vigilancia ambiental robusto que apoye la toma de decisiones estratégicas y las operaciones de interdicción en tiempo real.

La complejidad de detectar rezagos de minería ilegal radica en la sutileza de los cambios en la cobertura del suelo y la variabilidad de las firmas espectrales de los sitios intervenidos. A diferencia de la minería industrial, la minería artesanal y de pequeña escala (MAPE) ilegal se caracteriza por la fragmentación del paisaje, la creación de pozas de sedimentación de colores diversos y la instalación de campamentos rústicos bajo el dosel forestal. Para abordar este problema, la integración de redes neuronales convolucionales (CNN) de última generación, algoritmos de segmentación semántica y estructuras de datos optimizadas para grandes volúmenes de información geoespacial resulta imperativa.

Fundamentos de la Monitorización Satelital en Contextos de Minería

La detección de actividades mineras ilegales requiere una comprensión profunda de las tecnologías de observación terrestre. La monitorización de la Amazonía peruana, que abarca el 100% de su cuenca, se sustenta actualmente en el uso de cinco sistemas satelitales clave: Landsat, Planet, DigitalGlobe, Sentinel y Perusat. Cada uno de estos sistemas aporta una dimensión diferente al análisis, permitiendo un enfoque multiescalar que va desde la detección de cambios regionales hasta la identificación detallada de maquinaria específica.

Características de los Sensores y Resoluciones Espectrales

El programa Sentinel-2 de la Agencia Espacial Europea (ESA) se ha convertido en la herramienta predilecta para el entrenamiento de modelos de inteligencia artificial debido a su

resolución de 10 metros y su frecuencia de actualización de aproximadamente cinco días. Las bandas del infrarrojo cercano (NIR) y del infrarrojo de onda corta (SWIR) son particularmente valiosas, ya que permiten distinguir variaciones sutiles en la vegetación y detectar el estrés hídrico o la remoción de biomasa antes de que sea evidente en el espectro visible. Por otro lado, la serie Landsat, con más de tres décadas de datos, permite realizar análisis retrospectivos sobre el impacto acumulado de la minería en ríos de regiones como Madre de Dios.

Satélite	Resolución Espacial	Aplicación en Minería Ilegal	Disponibilidad de Datos
Sentinel-2	10 metros	Alertas tempranas y segmentación semántica	Acceso abierto (Copernicus)
Landsat 8/9	30 metros	Análisis histórico y cambios geomorfológicos	Acceso abierto (USGS)
PlanetScope	3 metros	Monitorización diaria de frentes activos	Comercial / NICFI
SkySat	0.50 metros	Identificación de maquinaria y campamentos	Comercial
Sentinel-1 (SAR)	10-20 metros	Detección en zonas de alta nubosidad	Acceso abierto (ESA)

El uso de sensores activos como el Radar de Apertura Sintética (SAR) en el satélite Sentinel-1 es crucial para regiones como Puno o la selva baja, donde la cobertura nubosa persiste durante gran parte del año. El SAR mide el coeficiente de retrodispersión (backscattering), el cual cambia drásticamente cuando la estructura del bosque denso es reemplazada por superficies lisas como pozas de agua o suelo desnudo. La integración de datos ópticos y de radar permite reducir los falsos negativos causados por la interferencia atmosférica.

Protocolo de Procesamiento Radiométrico y Atmosférico de Imágenes

La calidad de las predicciones de un modelo de visión computacional depende de la consistencia de los datos de entrenamiento. Las imágenes satelitales crudas, expresadas en Cuentas Digitales (DN), deben someterse a un flujo de procesamiento que elimine las distorsiones causadas por la atmósfera y la geometría del sensor.

Conversión de Valores y Calibración del Sensor

El primer paso es la conversión de los DN a valores físicos de radiancia o reflectancia en lo alto de la atmósfera (TOA). Este proceso utiliza coeficientes de escalado (gain y offset) específicos de cada banda, disponibles en los ficheros de metadatos (MTL o XML). La reflectancia TOA compensa las variaciones en la iluminación solar debido a la distancia Tierra-Sol y el ángulo cenital, pero no elimina el efecto de la atmósfera.

Modelos de Corrección Atmosférica y Eliminación de Bruma

Para obtener la reflectancia en superficie (Surface Reflectance), es necesario aplicar modelos de transferencia radiativa. Los modelos absolutos, como 6S y MODTRAN, son los más precisos pero requieren datos atmosféricos in situ sobre aerosoles y vapor de agua. En ausencia de estos datos, se emplean modelos relativos basados en la imagen, como el Dark Object Subtraction (DOS). El método DOS asume que existen píxeles en la imagen (como sombras o cuerpos de agua profundos) cuya reflectancia real debería ser cero; cualquier señal detectada en ellos se atribuye a la bruma atmosférica y se resta de toda la escena.

La estimación de la bruma (haze estimation) identifica los valores mínimos de DN en las bandas visibles para calcular el espesor óptico de la atmósfera. Este paso es vital para que el modelo de aprendizaje profundo no confunda la neblina con sedimentos en las pozas mineras. Asimismo, el enmascaramiento de nubes mediante algoritmos como Fmask o s2cloudless permite filtrar píxeles contaminados que podrían sesgar el entrenamiento del modelo.

Arquitectura de Algoritmos y Estructuras de Datos Multidimensionales

La detección automática de minería ilegal se basa en la capacidad de las redes neuronales para aprender patrones espaciales y espectrales complejos. En este contexto, el tratamiento de la información como matrices multidimensionales o tensores permite preservar la relación intrínseca entre las diferentes longitudes de onda.

El Papel de las Redes Neuronales Convolucionales (CNN)

Las CNN son la arquitectura fundamental para el análisis de imágenes debido a su capacidad de extraer características jerárquicas, desde bordes y texturas simples hasta formas complejas como balsas o parches de deforestación. Una CNN se compone de capas convolucionales que analizan píxeles adyacentes para detectar gradientes y orientaciones, seguidas de capas no lineales que activan funciones de probabilidad para la clasificación.

En tareas de segmentación semántica, el objetivo es realizar una "predicción densa", asignando una categoría a cada píxel individual de la imagen. Esto permite no solo saber que hay minería en una escena, sino delimitar con precisión su extensión y forma.

Comparativa de Modelos: U-Net, DeepLabV3+ y SegNet

La selección de la arquitectura es crítica para el rendimiento del sistema. La U-Net se ha consolidado como el estándar para segmentación en teledetección debido a su estructura simétrica de codificador-decodificador y al uso de "conexiones de salto" (skip connections). Estas conexiones permiten que la información espacial de alta resolución del codificador se combine con la información semántica del decodificador, facilitando la recuperación de detalles finos y bordes precisos en las pozas mineras.

Arquitectura	Característica Principal	Desempeño en Minería	Requerimientos de Hardware
U-Net	Conexiones de salto (skip connections)	Excelente en bordes y pequeñas manchas	Moderados (GPU estándar)

Arquitectura	Característica Principal	Desempeño en Minería	Requerimientos de Hardware
DeepLabV3+	Convoluciones atros (dilatadas)	Superior en capturar contexto multiescala	Altos (Gran capacidad de memoria)
SegNet	Índices de max-pooling para upsampling	Eficiente y ligero, pero menos preciso	Bajos (Sistemas embebidos)

Estudios recientes indican que la arquitectura DeepLabV3+, al utilizar convoluciones atros, puede capturar información de objetos a diferentes escalas sin perder resolución, lo cual es ideal para detectar desde pequeños socavones hasta grandes áreas de dragado aluvial. Sin embargo, U-Net con un backbone ResNet50 sigue ofreciendo el mejor balance entre precisión espacial y recall, alcanzando una precisión general de hasta 0.97 en la detección de parches mineros.

Optimización mediante Índices Espaciales y Tensores

El manejo de grandes volúmenes de datos satelitales requiere estructuras de datos que permitan búsquedas eficientes. Los índices espaciales como los R-trees organizan la información mediante rectángulos mínimos envolventes (MBR), agrupando objetos geográficos de manera jerárquica. Esto es esencial cuando se desea consultar rápidamente todas las áreas de minería detectadas dentro de un radio específico o una reserva protegida.

Los Quadtrees, por su parte, dividen el espacio bidimensional de forma recursiva en cuatro cuadrantes, siendo óptimos para la gestión de datos rasterizados y la visualización en diferentes niveles de zoom. En sistemas avanzados, se proponen estructuras híbridas como el Quad-KD tree, que combina la eficiencia de los Quadtrees para polígonos (áreas deforestadas) con la rapidez de los KD-trees para puntos (ubicación de maquinaria), reduciendo el tiempo de búsqueda en hasta un 68% en conjuntos de datos masivos.

La representación de las imágenes como tensores de alto orden permite aplicar descomposiciones tensoriales que separan el fondo (bosque) de las anomalías (minería). Esta técnica ayuda a combatir la "maldición de la dimensionalidad", donde el exceso de bandas espectrales puede dificultar el entrenamiento del modelo si no se maneja adecuadamente mediante modelos multilineales compactos.

Protocolo Operativo: Selección, Etiquetado y Entrenamiento

El desarrollo del modelo automatizado sigue una metodología rigurosa dividida en fases críticas que aseguran la validez de los resultados en condiciones reales de campo.

Construcción del Dataset y Etiquetado

La selección de imágenes debe priorizar escenas con baja cobertura nubosa (menor al 10%) para garantizar la calidad de la señal. El proceso de generación de cuadros (frame generation) utiliza productos de clasificación existentes, como MapBiomass, para identificar polígonos de minería conocidos que servirán como "verdad de campo" (ground truth). Es vital realizar una limpieza manual de estos polígonos, descartando aquellos menores a 50,000 m² para evitar ruidos y asegurar que el modelo aprenda características consistentes.

El dataset final debe ser heterogéneo, incluyendo diferentes tipos de suelo, estructuras de vegetación y configuraciones mineras (aluvial, socavón, dragado) para mejorar la capacidad de generalización del modelo. Para compensar la escasez de datos etiquetados en zonas de difícil acceso, se utilizan técnicas de aumento de datos (data augmentation), como rotaciones, reflexiones y variaciones de color, que multiplican la diversidad del conjunto de entrenamiento sin alterar el significado semántico de las imágenes.

Entrenamiento y Sensibilidad Espectral

El entrenamiento se realiza utilizando hardware de alto rendimiento, como servidores con NVIDIA RTX 4080s, empleando estrategias de validación cruzada para asegurar la estabilidad del modelo. La sensibilidad espectral es un factor determinante: se ha demostrado que la combinación de bandas RGB junto con el infrarrojo cercano (RGB-NIR) es la configuración óptima para la segmentación semántica con U-Net, alcanzando un mIoU (Mean Intersection over Union) de 0.60.

Donde TP representa los verdaderos positivos, FP los falsos positivos y FN los falsos negativos. Un mIoU alto indica que el modelo no solo detecta la presencia de minería, sino que su delimitación espacial es altamente precisa respecto a la máscara de referencia.

Estrategias de Aumento de Datos Específicas

Debido a que las imágenes satelitales son multiespectrales, el aumento de datos debe ir más allá de las transformaciones geométricas simples. Técnicas como el MixChannel sustituyen bandas de una imagen con las de otra toma de la misma área en una fecha diferente. Esto obliga a la red neuronal a aprender patrones estructurales y texturas en lugar de depender únicamente de la distribución espectral de un día concreto, lo cual es fundamental para detectar minería bajo diferentes condiciones de iluminación estacional.

Monitoreo Automatizado y Vigilancia en Tiempo Real

El objetivo final es la construcción de un sistema de monitorización automatizado que actúe como un geovisor en línea para las autoridades. Herramientas como Amazon Mining Watch (AMW) ya demuestran el potencial de esta integración, utilizando aprendizaje automático sobre imágenes Sentinel-2 de 10 metros para identificar zonas afectadas en toda la Amazonía.

Componentes de un Sistema de Alerta Temprana

1. **Detección de Píxeles:** El modelo resalta nuevos eventos de deforestación minera mediante polígonos rojos, permitiendo distinguir la actividad reciente de los pasivos ambientales históricos.
2. **Frecuencia de Actualización:** El sistema procesa datos trimestralmente, permitiendo una vigilancia casi en tiempo real de nuevos frentes mineros artesanales y de pequeña escala.
3. **Análisis de Legalidad:** El cruce automático con capas de áreas naturales protegidas y concesiones vigentes permite clasificar la presunción de ilegalidad de "muy alta" a "baja".
4. **Valoración de Daños:** Mediante la "Calculadora de Impactos de la Minería", el sistema utiliza fórmulas económicas para valorar los daños sociales y ambientales basándose en

el tamaño de la mina detectada y el tiempo de extracción. Este enfoque ha permitido identificar que en 2025 más de 200 áreas protegidas y territorios indígenas experimentaron nuevas actividades mineras, afectando un total de 14,004 hectáreas. La capacidad de detectar estas intrusiones de manera remota reduce el riesgo para los defensores ambientales y permite una asignación más eficiente de los recursos de vigilancia.

Impacto Ambiental y Acción Gubernamental en el Perú

La minería ilegal en el sur de la Amazonía peruana (Madre de Dios, Puno y Cusco) es responsable del 98.7% de la deforestación minera total del país. En Madre de Dios, epicentro de la crisis, se han identificado más de 2,000 infraestructuras mineras activas en 2025, incluyendo tracas, chutes y balsas.

Dinámica de Desplazamiento y Operación Mercurio

El monitoreo satelital ha sido fundamental para evaluar el éxito de intervenciones estatales como la Operación Mercurio (2019). Tras esta operación, la tasa mensual de deforestación por minería se redujo en un 62% a nivel general, y hasta un 90% en la zona crítica conocida como La Pampa. Sin embargo, la tecnología también reveló un "efecto globo": los mineros se desplazaron hacia áreas menos vigiladas, como Pariamanu y el río Chaspa en Puno, donde la actividad aumentó significativamente tras la intervención en las zonas centrales.

Zona de Estudio	Deforestación Pre-Intervención (ha/mes)	Deforestación Post-Intervención (ha/mes)	Variación (%)
La Pampa (Madre de Dios)	165	17	-90%
Pariamanu (Madre de Dios)	2.5	4.2	+70%
Chaspa (Puno)	0.0	8.5	Nuevo Frente
Total Sitios Monitoreados	279	105	-62%

Estos datos demuestran que la vigilancia no puede ser estática. Un sistema automatizado debe cubrir no solo los focos conocidos, sino realizar un barrido sistemático de las zonas de amortiguamiento y las comunidades indígenas, que han visto un incremento del 128% en la deforestación minera en años recientes.

Éxitos Recientes en Operaciones de Interdicción

La integración de alertas satelitales de alta resolución ha facilitado operaciones conjuntas exitosas entre el Ministerio del Ambiente (MINAM), el Servicio Nacional de Áreas Naturales Protegidas (SERNANP) y la Policía Nacional. En octubre de 2025, se ejecutó un golpe contra la minería ilegal en el sector Azul de la Reserva Nacional Tambopata, logrando la destrucción de campamentos y balsas traca. En 2026, el "Plan de Operaciones Restauración" permitió la georreferenciación de más de 20 puntos críticos en el sector Valle Dorado, resultando en la detonación de 49 balsas dragas y la inutilización de miles de metros de tuberías. Estas

acciones se sustentan legalmente en el Decreto Legislativo N° 1100, que autoriza la destrucción de maquinaria utilizada en actividades mineras prohibidas.

El Rol de la Visión Computacional en la Conservación y Justicia Ambiental

La implementación de modelos de visión computacional no es solo un avance técnico, sino una herramienta de justicia ambiental. Las comunidades indígenas, apoyadas por redes de observadores forestales y tecnologías como ForestLink, han logrado someter alertas que derivaron en denuncias aceptadas por la Fiscalía Especializada en Materia Ambiental (FEMA) de Madre de Dios. En 2025, de 42 alertas enviadas por observadores indígenas, 18 estaban directamente vinculadas a minería ilegal, demostrando que la tecnología potencia la participación ciudadana en la defensa del territorio.

La transparencia de los datos satelitales también influye en la política de formalización minera. Los mapas de zonificación forestal y las detecciones de IA permiten a las autoridades de formalización depurar el REINFO (Registro Integral de Formalización Minera), evitando que este sea utilizado como un "escudo de impunidad" por parte de operadores que actúan en zonas prohibidas.

Conclusiones y Futuras Líneas de Investigación

El desarrollo de un sistema automatizado para la detección de minería ilegal mediante visión computacional representa una solución moderna y precisa ante la magnitud de la degradación ambiental en la Amazonía. La combinación de redes CNN (U-Net y DeepLabV3+), el procesamiento de imágenes multiespectrales y el uso de estructuras de datos optimizadas permite una monitorización a gran escala que antes era impensable.

Las lecciones aprendidas de operaciones como Mercurio y Restauración subrayan la necesidad de sistemas que no solo detecten el daño, sino que apoyen la prevención mediante alertas tempranas. El futuro de esta tecnología reside en la integración de datos de radar de alta resolución para el monitoreo nocturno y bajo nubes, así como en la implementación de modelos de super-resolución que permitan extraer información detallada de imágenes de acceso abierto. Solo mediante un compromiso continuo con la innovación técnica y la articulación institucional será posible frenar el avance de la minería ilegal y asegurar la integridad de los ecosistemas más vulnerables del Perú.

Fuentes citadas

1. Imágenes satelitales muestran el impacto de 34 años de minería ilegal en ríos de Madre de Dios - Mongabay Latam, <https://es.mongabay.com/2020/02/peru-imagenes-satelitales-mineria-ilegal-rios-madre-de-dios/>
2. Perú: monitoreo satelital muestra que región perdió más de 18 mil hectáreas de bosque en dos años por minería legal e ilegal | Interferencia, <https://interferencia.cl/articulos/peru-monitoreo-satelital-muestra-que-region-perdio-mas-de-18-mil-hectareas-de-bosque-en>
3. Home - MAAP, <https://www.maaprogram.org/es/>
4. (PDF) Satellite Imagery Processing using NDVI for the Detection of Illegal Mining in Chaspa, Puno - Peru - ResearchGate,

https://www.researchgate.net/publication/373134963_Satellite_Imagery_Processing_using_ND_VI_for_the_Detection_of_Illegal_Mining_in_Chasca_Puno_-_Peru 5. MAAP #154: Minería Illegal en la Amazonía Peruana - Actualización 2022, https://www.maaprogram.org/es/mineria_peru/ 6. Mining Scene Classification and Semantic Segmentation Using 3D ..., <https://www.mdpi.com/2072-4292/18/8/1112> 7. A New Semantic Segmentation Framework Based on UNet - MDPI, <https://www.mdpi.com/1424-8220/23/19/8123> 8. MAAP#125: Detecting Illegal Logging With Very High Resolution Satellites - Amazon Conservation Association, <https://www.amazonconservation.org/tag/peru/page/2/> 9. MixChannel: Advanced Augmentation for Multispectral Satellite Images - MDPI, <https://www.mdpi.com/2072-4292/13/11/2181> 10. Teledetección Aplicada con QGIS: Casos Prácticos 5, <https://editorial.ual.es/media/unalmeria/files/sample-166343.pdf> 11. Colaboración para rastrear minas auríferas ilegales en Perú - NASA Ciencia, <https://ciencia.nasa.gov/ciencias-terrestres/minas-auriferas-ilegales-peru/> 12. Monitoreo de minería ilegal en la Amazonía con imágenes SAR y ópticas Planet - YouTube, https://www.youtube.com/watch?v=d1E6EApx_CM 13. PREPROCESAMIENTO DE IMÁGENES DE SATÉLITE ... - UNICAN, https://personales.unican.es/rasillad/docencia/g174/7_preprocesamiento/correccion.html 14. Flujo de procesamiento - Plan Nacional de Teledetección - PNT, <https://pnt.ign.es/flujo-de-procesamiento> 15. GERSL/Fmask: Cloud and cloud shadow detection algorithm for Landsat and Sentinel-2 imagery - GitHub, <https://github.com/gersl/fmask> 16. Best Sentinel-2 Cloud Mask: SCL vs s2cloudless vs FMask | ClearSKY Knowledge, <https://clearsky.vision/knowledge/best-sentinel-2-cloud-mask-scl-vs-s2cloudless-vs-fmask> 17. Project: Tensor-based methods for Hyperspectral Imaging References, <https://www.math.hkbu.edu.hk/project/24/33.pdf> 18. Fusing Hyperspectral and Multispectral Images via Low-Rank Hankel Tensor Representation - MDPI, <https://www.mdpi.com/2072-4292/14/18/4470> 19. A Survey of Deep Learning: Platforms, Applications and Emerging Research Trends, https://www.researchgate.net/publication/324815845_A_Survey_of_Deep_Learning_Platforms_Applications_and_Emerging_Research_Trends 20. Unified DeepLabV3+ for Semi-Dark Image Semantic Segmentation - MDPI, <https://www.mdpi.com/1424-8220/22/14/5312> 21. satellite-image-deep-learning/techniques - GitHub, <https://github.com/satellite-image-deep-learning/techniques> 22. Semantic Segmentation: Enriching Image Data in 2026, <https://labeyourdata.com/articles/data-annotation/semantic-segmentation> 23. Performance and Analysis of FCN, U-Net, and SegNet in Remote Sensing Image Segmentation Based on the LoveDA Dataset - ITM Web of Conferences, https://www.itm-conferences.org/articles/itmconf/pdf/2025/01/itmconf_dai2024_03023.pdf 24. Performance metrics comparison of UNet, SegNet, and DeeplabV3 models... | Download Scientific Diagram - ResearchGate, https://www.researchgate.net/figure/Performance-metrics-comparison-of-UNet-SegNet-and-DeeplabV3-models-with-and-without-a_tbl1_388111952 25. A Benchmark Study of DeepLabV3+, U-Net++, and Attention U-Net for Blood Cell Segmentation | Green Intelligent Systems and Applications - Tecno Scientifica Publishing, <https://tecnoscientifica.com/journal/gisa/article/view/607> 26. R-Trees: A Dynamic Index Structure for Spatial Searching. - DTIC, <https://apps.dtic.mil/sti/tr/pdf/ADA168531.pdf> 27. R-tree - Wikipedia, <https://en.wikipedia.org/wiki/R-tree> 28. addu390/hybrid-spatial-index: Hybrid Spatial Data ... - GitHub, <https://github.com/addu390/hybrid-spatial-index> 29. Spatial Indexing with QuadTrees - Medium,

<https://medium.com/@waleoyediran/spatial-indexing-with-quadtrees-b998ae49336> 30. Multi-Dimensional Low-Rank with Weighted Schatten p-Norm Minimization for Hyperspectral Anomaly Detection - MDPI, <https://www.mdpi.com/2072-4292/16/1/74> 31. Breaking the Curse of Dimensionality Using Decompositions of Incomplete Tensors: Tensor-based scientific computing in big data analysis | Request PDF - ResearchGate, https://www.researchgate.net/publication/264828550_Breaking_the_Curse_of_Dimensionality_Using_Decompositions_of_Incomplete_Tensors_Tensor-based_scientific_computing_in_big_data_analysis 32. Hybrid Methodology With Convolutional Neural Networks And Data Augmentation For Aerial Image Object Detection For Illegal Minery - ResearchGate, https://www.researchgate.net/publication/363284856_Hybrid_Methodology_With_Convolutional_Neural_Networks_And_Data_Augmentation_For_Aerial_Image_Object_Detection_For_Illegal_Minery 33. MAAP #235: Detección en tiempo real de la deforestación causada por minería aurífera en la Amazonía mediante IA, <https://www.maaprogram.org/es/mineria-amazonia-ai/> 34. MAAP #233: Situación actual de Minería de Oro en la Amazonía Peruana, <https://www.maaprogram.org/es/mineria-oro-peru-2025/> 35. MAAP #130: Illegal Gold Mining Down 78% In Peruvian Amazon, But Still Threatens Key Areas, <https://www.amazonconservation.org/maap-130-illegal-gold-mining-down-78-in-peruvian-amazon-but-still-threatens-key-areas/> 36. Perú: análisis satelital revela seis focos de minería ilegal tras Operación Mercurio en Madre de Dios - Mongabay Latam, <https://es.mongabay.com/2020/12/peru-imagenes-satelitales-operacion-mercurio/> 37. Golpe contra la minería ilegal en Madre de Dios: interdicción en el ..., <https://www.gob.pe/institucion/sernanp/noticias/1257555-golpe-contra-la-mineria-ilegal-en-madre-de-dios-interdicion-en-el-sector-azul-de-la-reserva-nacional-tambopata> 38. Golpe a la minería ilegal en Reserva Nacional de Tambopata, <https://especial.larepublica.pe/la-republica-sostenible/2026/04/28/golpe-a-la-mineria-ilegal-en-reserva-nacional-de-tambopata-1064532> 39. Indigenous forest observers drive action against illegal mining in the Peruvian Amazon, <https://www.rainforestfoundationuk.org/indigenous-forest-observers-drive-action-against-illegal-mining-in-the-peruvian-amazon/> 40. DETECCIÓN DE PATRONES DE MINERÍA ILEGAL A CIELO ABIERTO - Poder Espacial, <https://poderespacial.fac.mil.co/es/facsat/deteccion-de-patrones-de-mineria-ilegal-cielo-abierto-utilizando-redes-neuronales>